

Universidad Peruana

# Cayetano Heredia



UNIVERSIDAD PERUANA  
**CAYETANO HEREDIA**

# Introducción a la inteligencia artificial

Lewis De La Cruz



cayetano.edu.pe



# Implementación Práctica de Modelos de IA



**Según tu punto de vista.  
¿Qué es Inteligencia Artificial?**

- Escríbelo en los comentarios



# Tipos de inteligencia artificial

- Inteligencia artificial general
- Inteligencia artificial estrecha



# Inteligencia Artificial en salud



- Electronic Medical Records (EMRs)
  - Historia clínica electrónica en Perú
- Cloud computing
- mHealth

# IA en salud: estado del arte, desafíos y direcciones futuras

- Datos multi-ómicos
  - Predecir las tasas de remisión y la supervivencia en el cáncer de ovario
  - Predecir la resistencia a los fármacos en mutaciones de la proteasa del VIH




# IA en salud: estado del arte, desafíos y direcciones futuras



- Datos clínicos
  - Identificación de retinopatía diabética
  - Predicción del riesgo de aparición de insuficiencia cardíaca
  - Detección de arritmia cardíaca.
  - Marcadores en la actividad de las redes sociales asociados con el empeoramiento de la salud mental

# IA en salud: estado del arte, desafíos y direcciones futuras

- Datos ambientales
  - Exploración del efecto del medio ambiente en la fiebre aftosa.
  - Asociación entre la exposición a la contaminación del aire y las habilidades cognitivas de los niños en los Estados Unidos





# Desafíos

Según la OMS la salud es un estado de completo bienestar físico, mental y social, y no solamente la ausencia de afecciones o enfermedades.

## Desafío ambiental

Incluir los datos ambientales individuales a las historias clínicas electrónicas  
IA en entornos de escasos recursos



B. Wahl, A. Cossy-Gantner, S. Germann, y N. R. Schwalbe, «Artificial intelligence (AI) and global health: how can AI contribute to health in resource-poor settings?», *BMJ Glob. Health*, vol. 3, n.o 4, p. e000798, ago. 2018, doi: 10.1136/bmjgh-2018-000798.

F. Wang y A. Preininger, «AI in Health: State of the Art, Challenges, and Future Directions», *Yearb. Med. Inform.*, vol. 28, n.º 1, pp. 16-26, ago. 2019, doi: 10.1055/s-0039-1677908.

# Otros desafíos

- Actualización de base de conocimientos de los sistemas expertos
- Sesgos en la implantación



# Otros desafíos



- Datos de alta calidad
- Grandes cantidades de datos
- Almacenamiento de datos

B. Wahl, A. Cossy-Gantner, S. Germann, y N. R. Schwalbe, «Artificial intelligence (AI) and global health: how can AI contribute to health in resource-poor settings?», BMJ Glob. Health, vol. 3, n.o 4, p. e000798, ago. 2018, doi: 10.1136/bmjgh-2018-000798.



# Ley N° 29733, Ley de Protección de Datos Personales

- **Datos personales**

- Toda información de una persona que lo identifica

- **Datos sensibles**

- Datos biométricos; referidos al origen étnico; ingresos económicos; opiniones o convicciones políticas, religiosas, filosóficas o morales; afiliación sindical; e información relacionada a la salud o la vida sexual.



# Datos personales relacionado a la salud



- Aquella información concerniente a la salud pasada, presente o pronosticada, física o mental, de una persona, incluyendo el grado de discapacidad y su información genética



# Confidencialidad de la información del paciente

- Ley N° 26482, **Ley general de salud**
  - Toda información relativa al acto médico que se realiza tiene carácter reservado
- Ley N° 30024, **Ley que crea el registro nacional de historia clínicas electrónicas**
  - Los que intervengan en la gestión del Registro Nacional de Historias Clínicas Electrónicas están obligados a guardar confidencialidad respecto de este,



# Excepciones

- Hubiere consentimiento por escrito del paciente.
- Requerida por la autoridad judicial competente.
- **Con fines académicos o de investigación científica, siempre que la información obtenida de la historia clínica se consigne en forma anónima**



# Excepciones



El cumplimiento de una norma legal, que representa los intereses o necesidades de la nación, o la priorización de un interés público relevante, calificado como tal por el Poder Ejecutivo.





# Código Penal peruano

- **Artículo 154-A. Tráfico ilegal de datos personales**

El que ilegítimamente comercializa o vende información no pública relativa a cualquier ámbito de la esfera personal, familiar, patrimonial, laboral, financiera u otro de naturaleza análoga sobre una persona natural, será reprimido con pena privativa de libertad no menor de dos ni mayor de cinco años



| FDA definition                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                | TGA definition                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p><b>Section 201(h)</b> of the Food, Drug &amp; Cosmetic Act (FD&amp;C Act) defines a device as:</p> <ul style="list-style-type: none"> <li>an instrument, apparatus, implement, machine, contrivance, implant, in vitro reagent, or other similar or related article, including any component, part, or accessory, which is: <ul style="list-style-type: none"> <li>(1) recognized in the official National Formulary, or the United States Pharmacopeia, or any supplement to them,</li> <li>(2) <b>intended for</b> use in the <b>diagnosis</b> of disease or other conditions, or in the <b>cure, mitigation, treatment</b>, or <b>prevention</b> of disease, in man or other animals, or</li> <li>(3) <b>intended to affect the structure or any function</b> of the body of man or other animals, and</li> </ul> </li> <li>which does not achieve its primary intended purposes through <b>chemical action</b> within or on the body of man or other animals and which is not dependent upon being <b>metabolized</b> for the achievement of its primary intended purposes.</li> </ul> | <p><b>Section 41BD</b> of the Therapeutics and Goods Act defines a medical device as:</p> <p>Any instrument, apparatus, implement, machine, appliance, implant, software, material or other similar or related device (including any diagnostic product for in vitro use) that is intended by the manufacturer to be used, alone or in combination, for human beings for the specific purpose of one or more of the following:</p> <ul style="list-style-type: none"> <li>diagnosis, prevention, monitoring, treatment or alleviation of disease;</li> <li>diagnosis, monitoring, treatment, alleviation of or compensation for an injury or handicap;</li> <li>investigation, replacement, modification or support of the anatomy or of a physiological process;</li> <li>supporting or sustaining life;</li> <li>control of conception;</li> <li>disinfection of medical devices;</li> <li>providing information for medical purposes by means of in vitro examination of specimens derived from the human body;</li> <li>and <b>does not achieve its principal intended action</b> in or on the human body <b>by pharmacological, immunological or metabolic means</b>, but which may be assisted in its function by such means.</li> </ul> |





Health Topics ▾

Countries ▾

Newsroom ▾

Emergencies ▾

Data ▾

About WHO ▾

# Global Initiative on AI for Health

In **2018**, WHO partnered with the International Telecommunication Union (ITU), setting the stage for the **Focus Group on Artificial Intelligence for Health (FG-AI4H)**, a dynamic platform designed to provide answers to the pressing questions surrounding AI in healthcare.

With increasing global interest and participation in AI advancements, the FG-AI4H recognized the need for a long-term institutional structure. This partnership led to the formation of the **Global Initiative on AI for Health (GI-AI4H)**. Launched in July 2023, under WHO, ITU, and the World Intellectual Property Organization (WIPO), the GI-AI4H stands as a resilient, long-term institutional structure, grounded in its mission to enable, facilitate, and implement AI in healthcare.

**Enable**

Standards,  
governance,  
policies, and  
guidance on  
evidence-based  
AI4H

**Facilitate**

Pooled  
Investments &  
a global  
community of  
experts

**Implement**

Sustainable  
models of AI  
programs  
implementation  
at the country  
level

<https://www.who.int/initiatives/global-initiative-on-ai-for-health>

## Strategy and guidance



25 March 2025

**Ethics and governance of artificial intelligence for health: Guidance on large... multi-modal models**

[Download](#)

[Read More](#)



19 October 2023

**Regulatory considerations on artificial intelligence for health**

[Download](#)

[Read More](#)



17 November 2021

**Generating Evidence for Artificial Intelligence Based Medical Devices: A... Framework for Training**

[Download](#)

[Read More](#)



18 August 2021

**Global strategy on digital health 2020-2025**

[Download](#)

[Read More](#)



28 June 2021

**Ethics and governance of artificial intelligence for health: WHO guidance... Executive summary**

[Download](#)

[Read More](#)

<https://www.who.int/initiatives/global-initiative-on-ai-for-health>

**PODER EJECUTIVO****PRESIDENCIA DEL CONSEJO  
DE MINISTROS**

**Decreto Supremo que aprueba el  
Reglamento de la Ley N° 31814, Ley que  
promueve el uso de la inteligencia artificial  
en favor del desarrollo económico y social  
del país**

**DECRETO SUPREMO  
N° 115-2025-PCM**

LA PRESIDENTA DE LA REPÚBLICA

CONSIDERANDO:

Que, el Decreto Legislativo N° 1412, Decreto Legislativo que aprueba la Ley de Gobierno Digital, tiene por objeto establecer el marco de gobernanza del gobierno digital para la adecuada gestión de la identidad digital, servicios digitales, arquitectura digital, interoperabilidad, seguridad digital y datos, así como el régimen jurídico aplicable al uso transversal de

Que, a través de la Resolución Ministerial N° 132-2024-PCM se dispuso la publicación del proyecto de Reglamento de la Ley N° 31814, Ley que promueve el uso de la inteligencia artificial en favor del desarrollo económico y social del país, del Decreto Supremo que lo aprueba y su exposición de motivos; habiéndose recibido las opiniones, comentarios y/o sugerencias de las entidades públicas, sector privado, organizaciones de la sociedad civil y de la ciudadanía en general;

Que, posteriormente, desde el 25 de noviembre al 6 de diciembre de 2024, se realizó consulta pública sobre el proyecto de Reglamento de la Ley N° 31814, a través de la Plataforma Integral de Solicitudes Digitales del Estado Peruano - FACILITA PERÚ, donde se recibieron aportes y comentarios del sector público, del sector privado, la academia y la sociedad civil en general;

Que, en virtud a lo dispuesto en el numeral 33.2 del artículo 33 del Reglamento del Decreto Legislativo N° 1565, Decreto Legislativo que aprueba la Ley General de Mejora de la Calidad Regulatoria, aprobado por Decreto Supremo N° 023-2025-PCM, la presente norma cuenta con dictamen favorable de la Comisión Multisectorial de Calidad Regulatoria que valida el expediente de Análisis de Impacto Regulatorio Ex Ante correspondiente;

Que, en ese sentido, resulta necesario aprobar el Reglamento de la Ley N° 31814, la Ley N° 31814, Ley que promueve el uso de la inteligencia artificial en favor del desarrollo económico y social del país, a fin de establecer las disposiciones aplicables al uso, desarrollo y promoción de la inteligencia artificial en el marco del proceso nacional de transformación digital;



# Ley N° 31814, Ley que promueve el uso de la inteligencia artificial en favor del desarrollo económico y social del país

## **Artículo 24. Uso de sistemas basados en IA de riesgo alto**

i) Orienta el tamizaje, la evaluación, sugerencia de diagnóstico, manejo o pronóstico del estado de salud de personas que pueda tener un impacto significativo en su bienestar físico o mental, orden de priorización del daño en emergencias de las prestaciones de salud, y evaluación de datos personales sensibles de personas naturales incluyendo los registrados en las historias clínicas electrónicas (HCE). Se infiere las emociones de una persona física en los entornos de trabajo y en los centros educativos, excepto cuando el sistema basado en IA esté destinado a ser instalado o introducido en el mercado por motivos médicos o de seguridad.

## **CAPÍTULO II. MEDIDAS PARA GARANTIZAR LA TRANSPARENCIA Y LA PRIVACIDAD**

### **Artículo 25. Transparencia Algorítmica**

25.1 El desarrollador o implementador de un sistema basado en IA de riesgo alto debe establecer mecanismos para garantizar la transparencia algorítmica, permitiendo informar al usuario, de forma previa, clara y sencilla, sobre la finalidad o uso del sistema basado en IA, sus funcionalidades principales y el tipo de decisiones que puede tomar, con el objetivo de que el usuario comprenda cómo interactúa con él o con el servicio o producto que utiliza el sistema basado en IA como uno de sus componentes, respetando el secreto industrial y comercial.



# ¿Podemos aplicar IA en el Perú?

- Escríbelo en los comentarios o enciende tu micrófono





[Esta foto](#) de Autor desconocido está bajo licencia [CC BY](#)



cayetano.edu.pe







# Fundamentos de Machine learning



# Diagnóstico de enfermedades





# Entonces, ¿Qué es el aprendizaje de máquina?

“El aprendizaje de máquina es el campo de estudio que le da a la computadora la capacidad de aprender sin ser programada explícitamente.”

- Arthur Samuel (1959)



“Se dice que un programa de computadora aprende de la experiencia  $E$  con respecto a alguna clase de tareas  $T$  y la medida de desempeño  $P$ , si su desempeño en tareas en  $T$ , medido por  $P$ , mejora con la experiencia  $E$ .”

- Tom Mitchell (1998)



# Entonces, ¿Qué es el aprendizaje de máquina?

- Automatización de la automatización
- Hacer que las computadoras se programen
- ¡Deje que los datos hagan el trabajo!
- Usar la computadora para detectar automáticamente patrones en los datos y usarlos para hacer predicciones o decisiones.



# ¿Magia?


*¡NO!*




- *Semillas* = Algoritmos
- *Nutrientes* = Datos
- *Jardinero* = Tú
- *Plantas* = Modelos








# Aprendizaje Supervisado





# Aprendizaje No Supervisado

- Sin etiquetas / objetivos
- Sin realimentación
- Encontrar estructura oculta en datos




Asignar grupos a ejemplos no etiquetados (instancias, puntos de datos)



# Aprendizaje Reforzado

- Proceso de decisión
- Sistema de recompensas
- Aprende series de acciones

Punto de referencia actual de última generación: StarCraft II



# Representación de Datos

**Punto de dato:** Instancia de datos, vector de características

$$\mathbf{x} = (x_1, x_2, \dots, x_d) \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix}$$

**Atributo:** Cada elemento de  $\mathbf{x}$ , características medidas (observadas), variables.

$x_d$


**Número de Atributos:**

$d$




# Datos Estructurados

bases de datos, hojas de cálculo / archivos csv



# Datos no Estructurados


características como píxeles de imagen, señales de audio, oraciones de texto

[illegible]

# La metodología es clave del éxito



# CRISP-DM Process Diagram




Source: Kenneth Jensen






# CRISP-DM Process Diagram



Source: Kenneth Jensen

# CRISP-DM Process Diagram



Source: Kenneth Jensen




cayetano.edu.pe



11-Feb.-26

CAJETANO ES EXCELENTE

# CRISP-DM Process Diagram



Source: Kenneth Jensen



cayetano.edu.pe



11-Feb.-26

CAYETANO ES EXCELENTE

# Pasos del Aprendizaje Automático



# Pasos del Aprendizaje Automático



# Tipo de Datos

Las características **categóricas** provienen de un conjunto desordenado:

- Binario: ¿trabaja?
- Nominal: ciudad.

Las características **numéricas** provienen de conjuntos ordenados:

- Conteos discretos: edad.
- Ordinal: calificación.
- Continuo/valor real: altura.



# Recolección de Datos

- Puede **depender** de personas
  - Etiquetado manual para aprendizaje supervisado.
  - Conocimiento del dominio.
- La **precisión** de nuestro modelo predictivo dependerá:
  - **Cantidad de datos**
  - **Calidad de los datos**
  - **Algoritmo de aprendizaje**
- *El modelo de aprendizaje automático es tan bueno como lo son los datos a partir de los cuales fue construido.*





# Pasos del Aprendizaje Automático



# Conversión a características numéricas

A menudo se requiere valores reales:

| Age | City | Income    |   | Age | Van | Bur | Sur | Income    |
|-----|------|-----------|---|-----|-----|-----|-----|-----------|
| 23  | Van  | 22,000.00 |   | 23  | 1   | 0   | 0   | 22,000.00 |
| 23  | Bur  | 21,000.00 |   | 23  | 0   | 1   | 0   | 21,000.00 |
| 22  | Van  | 0.00      | → | 22  | 1   | 0   | 0   | 0.00      |
| 25  | Sur  | 57,000.00 |   | 25  | 0   | 0   | 1   | 57,000.00 |
| 19  | Bur  | 13,500.00 |   | 19  | 0   | 1   | 0   | 13,500.00 |
| 22  | Van  | 20,000.00 |   | 22  | 1   | 0   | 0   | 20,000.00 |

Esto se denomina codificación "1 de k".

- Ahora podemos interpretar ejemplos como puntos en el espacio:
  - Por ejemplo, el primer ejemplo está en (23,1,0,0,22000).




# Aproximación de imágenes y grafos

Podemos pensar en otros tipos de datos de esta manera:



→  
graycale  
intensity

| (1,1) | (2,1) | (3,1) | ... | (m,1) | ... | (m,n) |
|-------|-------|-------|-----|-------|-----|-------|
| 45    | 44    | 43    | ... | 12    | ... | 35    |





→  
adjacency  
matrix

| N1 | N2 | N3 | N4 | N5 | N6 | N7 |
|----|----|----|----|----|----|----|
| 0  | 1  | 1  | 1  | 1  | 1  | 1  |
| 0  | 0  | 0  | 1  | 0  | 1  | 0  |
| 0  | 0  | 0  | 0  | 0  | 1  | 0  |
| 0  | 0  | 0  | 0  | 0  | 0  | 0  |



# Preparación de Datos

- ¿Hay algo malo con los datos?
  - Ruido (ej., Distorsión en el teléfono).
  - Valores atípicos (ej., error del instrumento).
  - Valores faltantes (sin valor disponible o no aplicable)
  - Datos duplicados (repeticiones).
  - Codificación incorrecta (para texto)
  - Ejemplos mal etiquetados
  - Datos sesgados: Datos desequilibrados (Tengo muchas más muestras de una clase que el resto)
- ¿Necesita arreglar / eliminar datos?



# Pasos del Aprendizaje Automático



# Extracción de Características

Extraer más información de los datos existentes

- Más **útil**
- Con buenas características, la mayoría de los algoritmos pueden aprender más **rápido**

Puede ser un arte

- Requiere **pensamiento** y **conocimiento** de los datos.
- Dos pasos:
  - Transformación de variables (por ejemplo, fechas en días laborables, normalización)
  - Creación de características (p. Ej., N-gramas para textos, si la palabra está en mayúscula para detectar nombres, etc.)



# Selección de Características

Eliminar características que no son relevantes para la tarea:

| SID: | Age | Job? | City | Rating | Income    |
|------|-----|------|------|--------|-----------|
| 3457 | 23  | Yes  | Van  | A      | 22,000.00 |
| 1247 | 23  | Yes  | Bur  | BBB    | 21,000.00 |
| 6111 | 22  | No   | Van  | CC     | 0.00      |
| 1235 | 25  | Yes  | Sur  | AAA    | 57,000.00 |
| 8976 | 19  | No   | Bur  | BB     | 13,500.00 |
| 2345 | 22  | Yes  | Van  | A      | 20,000.00 |



# Transformación de Características

## Transformaciones matemáticas

- Discretización (binning): convierte los datos numéricos en categóricos.

| Age |   | < 20 | >= 20, < 25 | >= 25 |
|-----|---|------|-------------|-------|
| 23  |   | 0    | 1           | 0     |
| 23  | → | 0    | 1           | 0     |
| 22  |   | 0    | 1           | 0     |
| 25  |   | 0    | 0           | 1     |
| 19  |   | 1    | 0           | 0     |
| 22  |   | 0    | 1           | 0     |

# Transformación de Características

## Transformaciones matemáticas

- Discretización (binning): convierte los datos numéricos en categóricos.
- Elevar al cuadrado, aplicar logaritmo, etc.

Escala: convierte variables a escalas comparables

(Por ejemplo, convertir kilogramos a gramos).



# Pasos del Aprendizaje Automático



# Selección de un modelo

- Tipo de problema (p. Ej., Clasificación, regresión, agrupación)
- Naturaleza, tipo y tamaño de los datos

## **Supervisados:**

- Clasificador lineal
- Naive Bayes
- Support Vector Machines (SVM)
- Decision Tree
- Random Forests
- k-Nearest Neighbors
- Neural Networks (Deep learning)

## **No Supervisados:**

- PCA
- t-SNE
- k-means
- DBSCAN

## **Reforzamiento:**

- SARSA- $\lambda$
- Q-Learning



# Pasos del Aprendizaje Automático



# Entrenamiento

- El objetivo del entrenamiento/aprendizaje es encontrar un modelo y sus parámetros correspondientes de modo que el modelo resultante funcione bien en datos no vistos.

- ¿Lo que podría suceder?



- ¿Qué podría ayudar?

- Selección de características
- Regularización
- Arquitectura del modelo
- Más datos



# Evaluación

- Dividir en conjunto de entrenamiento y de prueba. **No deben superponerse!**
- **Accuracy**
  - ¿Qué porcentaje de muestras se obtuvo correctamente?
- **Precision/Recall**
  - Positivos verdaderos (TP), negativos verdaderos(TN), falsos positivos (FP), falsos negativos (FN).
  - Precisión =  $TP / (TP + FP)$  (de todos los clasificadores etiquetados como positivos, que % realmente fue)
  - Recall =  $TP / (TP + FN)$  (de todo lo positivo, ¿cuántos acertaron?)
- **Medida F (media armónica,  $2 * Precision * Recall / (Precision + Recall)$ )**
- **Matriz de confusión**
- **Muchos otros**






# Pasos del Aprendizaje Automático



# Ajuste de parámetros

- Proceso experimental
- Mejora incremental:




- Arte más que ciencia
- Uso de métricas para evaluar el desempeño y comparar soluciones.

# Pasos del Aprendizaje Automático



# Predicción



# Aprendizaje Supervisado




cayetano.edu.pe



# Introducción: Alergia Alimentaria

Con frecuencia comienza a tener malestar estomacal



La sospecha es una posible alergia alimentaria



# Introducción: Alergia Alimentaria

Para resolver el misterio, comienzas a registrar todos los alimentos que comes:

| huevos | leche | pescado | trigo | marisco | maní | ... | enfermo? |
|--------|-------|---------|-------|---------|------|-----|----------|
| 0      | 0.7   | 0       | 0.3   | 0       | 0    |     | 1        |
| 0.3    | 0.7   | 0       | 0.6   | 0       | 0.01 |     | 1        |
| 0      | 0     | 0       | 0.8   | 0       | 0    |     | 0        |
| 0.3    | 0.7   | 1.2     | 0     | 0.1     | 0.01 |     | 1        |
| 0.3    | 0     | 1.2     | 0.3   | 0.1     | 0.01 |     | 1        |

Pero es difícil encontrar el patrón:

- No se puede aislar y solo comer una comida a la vez.
- Puede ser alérgico a más de un alimento.
- La cantidad importa: una pequeña cantidad puede estar bien.
- Puede ser alérgico a interacciones específicas.



# Introducción: Alergia Alimentaria

Podemos formular esto como aprendizaje supervisado:

| huevos | leche | pescado | trigo | marisco | maní | ... |   | enfermo? |
|--------|-------|---------|-------|---------|------|-----|---|----------|
| 0      | 0.7   | 0       | 0.3   | 0       | 0    |     | → | 1        |
| 0.3    | 0.7   | 0       | 0.6   | 0       | 0.01 |     | → | 1        |
| 0      | 0     | 0       | 0.8   | 0       | 0    |     | → | 0        |
| 0.3    | 0.7   | 1.2     | 0     | 0.1     | 0.01 |     | → | 1        |
| 0.3    | 0     | 1.2     | 0.3   | 0.1     | 0.01 |     | → | 1        |

La entrada para un ejemplo (día de la semana) es un conjunto de características (cantidades de alimentos).

- La salida es una etiqueta de clase deseada (si nos enfermamos o no).
- Objetivo del aprendizaje supervisado:
  - Utilice los datos para encontrar un modelo que muestre la etiqueta correcta según las características.
  - El modelo predice si los alimentos te enfermarán (incluso con nuevas combinaciones).



# Aprendizaje Supervisado


Problema general de aprendizaje supervisado:

- Tomar características de ejemplos y sus respectivas etiquetas como entradas.
- Encontrar un modelo que pueda predecir con precisión las etiquetas de nuevos ejemplos.
- Tiene que ser capaz de generalizar: dar los resultados correctos cuando se ingresan nuevos datos sin conocer un objetivo previo.

Aplicaciones: Filtrado de spam, reconocimiento óptico de caracteres, reconocimiento de voz, clasificación de tumores, etc.



# Aprendizaje Supervisado




## Regresión



# Regresión

- predecir nuevos valores basados en el pasado, inferencia
- calcular los nuevos valores para una variable dependiente basándose en los valores de uno o más atributos medidos




## Regresión

Predecir un valor continuo utilizando datos de entrenamiento



# Regresión Lineal y Regresión Múltiple



# Regresión Lineal o Bivariada

x es la variable independiente

y es la variable dependiente

El modelo de regresión es

$$y = \beta_0 + \beta_1 x + \varepsilon$$

El modelo tiene dos variables, la variable independiente o explicativa, x, y la variable dependiente y, la variable cuya variación se explica.

La relación entre x e y es una relación lineal o en línea recta. Dos parámetros para estimar: la pendiente de la línea  $\beta_1$  y la intersección con el eje y  $\beta_0$  (donde la línea cruza el eje vertical).

$\varepsilon$  es el componente inexplicable, aleatorio o de error.



# Línea de Regresión

El modelo de regresión es

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Los datos sobre x e y se obtienen de una muestra. De la muestra de valores de x e y, las estimaciones  $b_0$  de  $\beta_0$  y  $b_1$  de  $\beta_1$  se obtienen utilizando los mínimos cuadrados u otro método.

La estimación resultante del modelo es

$$\hat{y} = b_0 + b_1 x$$

El símbolo se denomina "y sombrero" y se refiere a los valores predichos de la variable dependiente y que están asociados con los valores de x, dado el modelo lineal.



# Regresión Ejemplo

| <u>Sueldo</u> | <u>hrs/semana</u> |  | <u>Sueldo</u> | <u>hrs/semana</u> |
|---------------|-------------------|--|---------------|-------------------|
| 8000          | 38                |  | 8000          | 35                |
| 6400          | 50                |  | 18000         | 37.5              |
| 2500          | 15                |  | 5400          | 37                |
| 3000          | 30                |  | 15000         | 35                |
| 6000          | 50                |  | 3500          | 30                |
| 5000          | 38                |  | 24000         | 45                |
| 8000          | 50                |  | 1000          | 4                 |
| 4000          | 20                |  | 8000          | 37.5              |
| 11000         | 45                |  | 2100          | 25                |
| 25000         | 50                |  | 8000          | 46                |
| 4000          | 20                |  | 4000          | 30                |
| 8800          | 35                |  | 1000          | 200               |
| 5000          | 30                |  | 2000          | 200               |
| 7000          | 43                |  | 4800          | 30                |







# Regresión Ejemplo



# Regresión Ejemplo



# Regresión Ejemplo



Regresión Lineal  
no es Suficiente

# Regresión Múltiple o Multivariada

La regresión múltiple tiene más de una variable independiente.

## Regresión Simple

- Una variable dependiente  $Y$  predicha a partir de una variable independiente  $X$

- Un coeficiente de regresión

## Regresión Múltiple

- Una variable dependiente  $Y$  predicha a partir de un conjunto de variables independientes ( $X_1, X_2, \dots, X_k$ )

- Un coeficiente de regresión

para cada variable independiente



# Línea de Regresión

La ecuación para este modelo ajustado a los datos es

$$\hat{y} = b_0 + b_1x_1 + \boxed{?} + b_px_p$$

Donde denota el valor "predicho" calculado a partir de la ecuación, y  $b_i$  denota una estimación de  $\beta_i$ .

Al igual que con la regresión lineal simple, se obtienen mediante el método de mínimos cuadrados

Entre el conjunto de todos los valores posibles para las estimaciones de los parámetros, encuentro los que minimizan la suma de los residuos al cuadrado.



# Regresión Logística

El modelo “logit” resuelve los siguientes problemas:

$$\ln[p/(1-p)] = \alpha + \beta X + e$$

- $p$  es la probabilidad de que el evento  $Y$  ocurra,  $p(Y=1)$
- $p/(1-p)$  es la "proporción de probabilidades"
- $\ln[p/(1-p)]$  es el logaritmo de la proporción de probabilidades o también conocido como "logit"




# Regresión Logística

- La distribución logística limita las probabilidades estimadas a estar entre 0 y 1.
- La probabilidad estimada es:  $p = 1 / [1 + \exp (-\alpha - \beta X)]$  o si deja  $\alpha + \beta X = 0$ , entonces  $p = .50$
- a medida que  $\alpha + \beta X$  se vuelve realmente grande,  $p$  se acerca a 1
- a medida que  $\alpha + \beta X$  se vuelve realmente pequeño,  $p$  se acerca a 0



# Regresión Lineal vs Logística






## Clasificación




# Clasificación

- dividir muestras en clases
- utilizar un conjunto entrenado de datos previamente etiquetados



# Clasificación

- dividir muestras en clases
- utilizar un conjunto entrenado de datos previamente etiquetados



# Modelo de Clasificación

Aprender un modelo de clasificación a partir de los datos que se puede utilizar para predecir las clases de nuevas instancias (futuras o de prueba).

$$y = f(x)$$

donde  $y$  = salida (clase),  $f()$  la función de clasificación y  $x$  la entrada.

Aprendizaje: dado un conjunto de entrenamiento de ejemplos etiquetados  $\{(x_1, y_1), \dots, (x_N, y_N)\}$ , estime los parámetros de la función de predicción  $f$

Inferencia: aplique  $f$  a un ejemplo de prueba  $x$  nunca antes visto y genere el valor predicho  $y = f(x)$




# Clasificación de Imágenes - Ejemplo

| Entrada                                                                             | Salida Deseada |
|-------------------------------------------------------------------------------------|----------------|
|    | Manzana        |
|    | Pera           |
|    | Tomate         |
|    | Vaca           |
|   | Perro          |
|  | Caballo        |

|                                                                                       |    |
|---------------------------------------------------------------------------------------|----|
|    | 0  |
|    | 1  |
|    | 2  |
|   | 1  |
|  | ?? |


# Clasificación - Datos Sísmicos



# Clasificación por Nearest Neighbor


¿El documento \* debería ser asignado a los documentos de UK, China o Kenya?

Idea básica: Clasificar el documento de prueba como la clase del documento "más cercano" al documento de consulta (use la similitud vectorial para encontrar el documento más similar)



# Clasificación por Nearest Neighbor

Clasificar el documento de prueba como la clase de la mayoría de los documentos  $k$  “más cercanos” al documento de consulta.






# Clasificación por Nearest Neighbor

kNN = k vecinos más cercanos.

- Para  $k=1$  (1NN), asignamos el documento de prueba al documento más cercano en el conjunto de entrenamiento.
- 1NN no es tan robusto, ya que un documento puede ser etiquetado de forma errónea o puede ser un documento atípico.
- Para  $k>1$ , asignamos el documento a la clase de la mayoría de los k documentos más cercanos en el conjunto de entrenamiento.

# Clasificación Lineal




Encontrar una función lineal para separar las clases

$$f(x) = \text{sgn}(w_1x_1 + w_2x_2 + \dots + w_Dx_D) = \text{sgn}(w \cdot x)$$




# Función Discriminante


Pueden ser funciones arbitrarias de  $\mathbf{x}$ , como:



Vecinos Cercanos



Árbol de Decisión



Funciones Lineales

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$




# Función Discriminante Lineal

$g(x)$  es una función lineal:

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

Un hiperplano en el espacio de características


¿Cómo clasificaría estos puntos usando una función discriminante lineal para minimizar la tasa de error? ¡Número infinito de respuestas!



# Función Discriminante Lineal

¿Cómo clasificaría estos puntos usando una función discriminante lineal para minimizar la tasa de error? ¡Número infinito de respuestas!

¿Cuál es mejor?




# Clasificador lineal de margen grande

La función discriminante lineal (clasificador) con el margen máximo es la mejor

El margen se define como el ancho que podría aumentar el límite antes de llegar a un punto de datos.

¿Por qué es el mejor? fuerte capacidad de generalización




# Clasificador lineal de margen grande

La función discriminante lineal (clasificador) con el margen máximo es la mejor

El margen se define como el ancho que podría aumentar el límite antes de llegar a un punto de datos.

¿Por qué es el mejor? fuerte capacidad de generalización




# Clasificador lineal de margen grande

Formulación

$$\text{minimize } \frac{1}{2} \|\mathbf{w}\|^2$$

Tal que


$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$$





# SVMs no lineales

Idea general: el espacio de entrada original se puede asignar a un espacio de características de mayor dimensión donde el conjunto de entrenamiento es separable:



# SVMs no lineales: El truco del Kernel

Ejemplos de funciones del kernel de uso común:

- ▣ Linear kernel:  $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$
- ▣ Polynomial kernel:  $K(\mathbf{x}_i, \mathbf{x}_j) = (1 + \mathbf{x}_i^T \mathbf{x}_j)^p$
- ▣ Gaussian (Radial-Basis Function (RBF) ) kernel:  
$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$$
- ▣ Sigmoid:  
$$K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta_0 \mathbf{x}_i^T \mathbf{x}_j + \beta_1)$$



# Gracias

Mg. Lewis De La Cruz

[umbert.de.la.cruz@upch.pe](mailto:umbert.de.la.cruz@upch.pe)



[cayetano.edu.pe](http://cayetano.edu.pe)



CAYETANO ES EXCELENCIA